

Regresión lineal simple vs regresión logística simple

brayan alexander diaz lievano

2026-06-13

Objetivo de la práctica

En esta práctica se busca comparar, de manera visual y sencilla, la diferencia entre un modelo de **regresión lineal simple** y un modelo de **regresión logística simple**.

La idea principal es la siguiente:

- La **regresión lineal simple** se usa cuando la variable respuesta es numérica y continua.
- La **regresión logística simple** se usa cuando la variable respuesta es binaria, por ejemplo: sí/no, aprueba/no aprueba, enfermedad/no enfermedad, default/no default.

En esta práctica veremos qué ocurre si intentamos ajustar una recta a una variable binaria y por qué la regresión logística es una mejor alternativa.

1. Simulación de datos sencillos

Primero generamos datos artificiales. La variable x representa una característica numérica. La variable y solo puede tomar los valores 0 y 1.

```
set.seed(123)

x <- rnorm(150, mean = 10, sd = 4)
error <- rnorm(150, mean = 0, sd = 2)

y <- ifelse(x + error > 10, 1, 0)

sim <- data.frame(x, y)
head(sim)
```

```
##           x y
## 1  7.758097 0
## 2  9.079290 1
## 3 16.234833 1
## 4 10.282034 0
## 5 10.517151 1
## 6 16.860260 1
```

La variable y es binaria:

- $y = 0$: no ocurre el evento.
- $y = 1$: ocurre el evento.


Pregunta 1. ¿Qué significa que una variable sea binaria?

Respuesta: _____ una variable binaria es una variable que solo puede tomar dos valores 0 y 1 _____

2. Gráfica inicial de los datos

```
library(ggplot2)

ggplot(sim, aes(x = x, y = y, color = as.factor(y))) +
  geom_point(size = 2, alpha = 0.75) +
  scale_color_manual(values = c("0" = "#2C7FB8", "1" = "#D95F02")) +
  labs(title = "Datos simulados con respuesta binaria",
       x = "Variable explicativa x",
       y = "Respuesta y",
       color = "Clase") +
  theme_minimal()
```



En la gráfica se observa que la variable respuesta no toma muchos valores posibles, sino únicamente 0 o 1. Esto es importante porque una recta no siempre es adecuada para este tipo de respuesta.

Pregunta 2. ¿Cuáles son los únicos valores que toma la variable y?

Respuesta: _____ los únicos valores que toma la variable y son 0 y 1 donde 0 indica que el evento no ocurre y 1 indica que sí ocurre.

3. Ajuste de regresión lineal simple

Aunque la variable y es binaria, primero ajustamos una regresión lineal simple para observar qué problema aparece.

```
modelo_lineal <- lm(y ~ x, data = sim)
summary(modelo_lineal)
```

```
##
## Call:
## lm(formula = y ~ x, data = sim)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.66195 -0.29233 -0.01291  0.27454  0.78725
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.475851   0.077840  -6.113 8.27e-09 ***
## x              0.097199   0.007342  13.238 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3405 on 148 degrees of freedom
## Multiple R-squared:  0.5422, Adjusted R-squared:  0.5391
## F-statistic: 175.3 on 1 and 148 DF,  p-value: < 2.2e-16
```

El modelo lineal tiene la forma:


$$\hat{y} = b_0 + b_1 x.$$

Sin embargo, cuando y es binaria, el valor ajustado se suele interpretar como una probabilidad. Esto puede generar problemas, porque una recta puede producir valores menores que 0 o mayores que 1.

```
ggplot(sim, aes(x = x, y = y, color = as.factor(y))) +
  geom_point(size = 2, alpha = 0.75) +
  geom_smooth(method = "lm", se = FALSE, color = "#1B9E77", linewidth = 1.2) +
  scale_color_manual(values = c("0" = "#2C7FB8", "1" = "#D95F02")) +
  labs(title = "Ajuste con regresión lineal simple",
        subtitle = "La recta no está restringida al intervalo [0,1]",
        x = "Variable explicativa x",
        y = "Respuesta y",
        color = "Clase") +
  theme_minimal()
```

Ajuste con regresión lineal simple

La recta no está restringida al intervalo [0,1]



Pregunta 3. ¿Por qué una recta puede ser problemática cuando queremos estimar probabilidades?

Respuesta: _____ porque una recta puede generar probabilidades menores que 0 o mayores que 1 y las probabilidades deben estar siempre entre 0 y 1 _____ # 4. Ajuste de regresión logística simple

Ahora ajustamos una regresión logística simple. Este modelo está diseñado para respuestas binarias.

```
modelo_logistico <- glm(y ~ x, data = sim, family = binomial)
summary(modelo_logistico)

##
## Call:
## glm(formula = y ~ x, family = binomial, data = sim)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -10.8188      1.8578  -5.823 5.77e-09 ***
## x              1.0923      0.1872   5.835 5.38e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 207.837  on 149  degrees of freedom
## Residual deviance:  85.239  on 148  degrees of freedom
## AIC: 89.239
##
## Number of Fisher Scoring iterations: 7
```

La regresión logística no modela directamente a y , sino la probabilidad de que ocurra el evento:


$$P(Y = 1 \mid X = x).$$

Por eso, sus predicciones siempre quedan entre 0 y 1.

```
sim$prob_logistica <- predict(modelo_logistico, type = "response")
head(sim)
```

```
##           x y prob_logistica
## 1  7.758097 0   0.08751308
## 2  9.079290 1   0.28880173
## 3 16.234833 1   0.99900819
## 4 10.282034 0   0.60170602
## 5 10.517151 1   0.66136963
## 6 16.860260 1   0.99949888
```

```
ggplot(sim, aes(x = x, y = y, color = as.factor(y))) +
  geom_point(size = 2, alpha = 0.75) +
  geom_line(aes(y = prob_logistica), color = "#7570B3", linewidth = 1.3) +
  scale_color_manual(values = c("0" = "#2C7FB8", "1" = "#D95F02")) +
  labs(title = "Ajuste con regresión logística simple",
       subtitle = "La curva representa una probabilidad entre 0 y 1",
       x = "Variable explicativa x",
       y = "Probabilidad estimada",
       color = "Clase") +
  theme_minimal()
```



Pregunta 4. ¿Qué representa la curva logística?

Respuesta: _____ la curva logistica representa la probabilidad estimada de que ocurra el evento $y = 1$ para cada valor de x _____

5. Comparación de ambos modelos

Calculamos las predicciones de ambos modelos para visualizar la diferencia.

```
sim$pred_lineal <- predict(modelo_lineal)
sim$pred_logistica <- predict(modelo_logistico, type = "response")


head(sim)
```

##	x	y	prob_logistica	pred_lineal	pred_logistica
## 1	7.758097	0	0.08751308	0.2782283	0.08751308
## 2	9.079290	1	0.28880173	0.4066468	0.28880173
## 3	16.234833	1	0.99900819	1.1021580	0.99900819
## 4	10.282034	0	0.60170602	0.5235522	0.60170602
## 5	10.517151	1	0.66136963	0.5464054	0.66136963
## 6	16.860260	1	0.99949888	1.1629488	0.99949888

```
ggplot(sim, aes(x = x, y = y)) +
  geom_point(aes(color = as.factor(y)), size = 2, alpha = 0.70) +
  geom_line(aes(y = pred_lineal), color = "#1B9E77", linewidth = 1.2) +
  geom_line(aes(y = pred_logistica), color = "#7570B3", linewidth = 1.2) +
  scale_color_manual(values = c("0" = "#2C7FB8", "1" = "#D95F02")) +
  labs(title = "Comparación: regresión lineal vs regresión logística",
       subtitle = "Verde: modelo lineal | Morado: modelo logístico",
       x = "Variable explicativa x",
       y = "Valor estimado / probabilidad estimada",
       color = "Clase") +
  theme_minimal()
```

Comparación: regresión lineal vs regresión logística

Verde: modelo lineal | Morado: modelo logístico



Interpretación:

La regresión lineal ajusta una recta. En cambio, la regresión logística ajusta una curva en forma de S. Esta curva es más adecuada cuando queremos estimar probabilidades de una respuesta binaria.

Interpretación. Completa la frase: **Pregunta 5.** A partir del diagrama de caja, ¿los clientes con default parecen tener balances más altos?

Respuesta: _____ si los clientes con default parecen tener balances mas altos que los clientes sin default. _____

6. Ejemplo aplicado: base de datos Default

Ahora usamos la base `Default`, incluida en el paquete `ISLR`. Esta base contiene información de clientes y permite estudiar si una persona cae o no en default.

```
library(ISLR)
```

```
datos_originales <- Default
head(datos_originales)
```

```
## default student balance income
## 1      No      No  729.5265 44361.625
## 2      No     Yes  817.1804 12106.135
## 3      No      No 1073.5492 31767.139
## 4      No      No  529.2506 35704.494
## 5      No      No  785.6559 38463.496
## 6      No     Yes  919.5885  7491.559
```

En esta práctica usaremos únicamente dos variables:


- balance: saldo promedio de la tarjeta.
- default: indica si el cliente cayó en default.

```
datos <- data.frame(  
  balance = datos_originales$balance,  
  default = datos_originales$default  
)  
  
datos$default_num <- ifelse(datos$default == "Yes", 1, 0)  
  
head(datos)
```

```
##      balance default default_num  
## 1  729.5265      No           0  
## 2  817.1804      No           0  
## 3 1073.5492      No           0  
## 4  529.2506      No           0  
## 5  785.6559      No           0  
## 6  919.5885      No           0
```


7. Exploración visual de los datos

```
ggplot(datos, aes(x = default, y = balance, fill = default)) +  
  geom_boxplot(alpha = 0.75) +  
  scale_fill_manual(values = c("No" = "#2C7FB8", "Yes" = "#D95F02")) +  
  labs(title = "Saldo promedio según condición de default",  
       x = "Default",  
       y = "Balance",  
       fill = "Default") +  
  theme_minimal()
```

Esta gráfica ayuda a ver si los clientes con default tienden a tener saldos mayores.

```
ggplot(datos, aes(x = balance, y = default_num, color = default)) +  
  geom_point(alpha = 0.35, size = 1.7) +  
  scale_color_manual(values = c("No" = "#2C7FB8", "Yes" = "#D95F02")) +  
  labs(title = "Relación entre balance y default",  
        x = "Balance",  
        y = "Default numérico",  
        color = "Default") +  
  theme_minimal()
```




8. Regresión lineal simple aplicada a una variable binaria

Ajustamos un modelo lineal usando `balance` como variable explicativa y `default_num` como variable respuesta.

```
modelo_lineal_default <- lm(default_num ~ balance, data = datos)
summary(modelo_lineal_default)
```

```
##
## Call:
## lm(formula = default_num ~ balance, data = datos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.23533 -0.06939 -0.02628  0.02004  0.99046
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -7.519e-02  3.354e-03  -22.42  <2e-16 ***
## balance      1.299e-04  3.475e-06   37.37  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1681 on 9998 degrees of freedom
## Multiple R-squared:  0.1226, Adjusted R-squared:  0.1225
## F-statistic: 1397 on 1 and 9998 DF, p-value: < 2.2e-16
```

```
ggplot(datos, aes(x = balance, y = default_num, color = default)) +
  geom_point(alpha = 0.35, size = 1.7) +
  geom_smooth(method = "lm", se = FALSE, color = "#1B9E77", linewidth = 1.2) +
  scale_color_manual(values = c("No" = "#2C7FB8", "Yes" = "#D95F02")) +
  labs(title = "Regresión lineal simple aplicada a default",
       subtitle = "La recta puede no representar bien una probabilidad",
       x = "Balance",
       y = "Default numérico",
       color = "Default") +
  theme_minimal()
```



Pregunta 6. ¿Qué problema puede tener la recta al interpretarla como probabilidad?

Respuesta: _____ porque puede dar valores que no son probabilidades válidas, como números menores que 0 o mayores que 1 _____

9. Regresión logística simple aplicada a Default

Ahora ajustamos el modelo correcto para una respuesta binaria.

```
modelo_logistico_default <- glm(default_num ~ balance,
                                data = datos,
                                family = binomial)
summary(modelo_logistico_default)
```

```
##
## Call:
## glm(formula = default_num ~ balance, family = binomial, data = datos)
```


```
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.065e+01  3.612e-01 -29.49  <2e-16 ***
## balance      5.499e-03  2.204e-04   24.95  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 1596.5  on 9998  degrees of freedom
## AIC: 1600.5
##
## Number of Fisher Scoring iterations: 8
datos$prob_default <- predict(modelo_logistico_default, type = "response")
head(datos)

##      balance default default_num prob_default
## 1  729.5265      No           0 0.0013056797
## 2  817.1804      No           0 0.0021125949
## 3 1073.5492      No           0 0.0085947405
## 4   529.2506      No           0 0.0004344368
## 5   785.6559      No           0 0.0017769574
## 6   919.5885      No           0 0.0037041528

ggplot(datos, aes(x = balance, y = default_num, color = default)) +
  geom_point(alpha = 0.35, size = 1.7) +
  geom_line(aes(y = prob_default), color = "#7570B3", linewidth = 1.3) +
  scale_color_manual(values = c("No" = "#2C7FB8", "Yes" = "#D95F02")) +
  labs(title = "Regresión logística simple aplicada a default",
       subtitle = "La curva estima la probabilidad de caer en default",
       x = "Balance",
       y = "Probabilidad estimada",
       color = "Default") +
  theme_minimal()
```

Regresión logística simple aplicada a default

La curva estima la probabilidad de caer en default



Pregunta 7. ¿Qué ocurre con la probabilidad de default cuando aumenta balance?

Respuesta: _____ cuando aumenta balance aumenta la probabilidad de que un cliente caiga en default _____

10. Comparación final en la base Default

```
datos$pred_lineal <- predict(modelo_lineal_default)
datos$pred_logistica <- predict(modelo_logistico_default, type = "response")
```

```
head(datos)
```

##	balance	default	default_num	prob_default	pred_lineal	pred_logistica
## 1	729.5265	No	0	0.0013056797	0.019553239	0.0013056797
## 2	817.1804	No	0	0.0021125949	0.030937043	0.0021125949
## 3	1073.5492	No	0	0.0085947405	0.064232213	0.0085947405
## 4	529.2506	No	0	0.0004344368	-0.006457028	0.0004344368
## 5	785.6559	No	0	0.0017769574	0.026842885	0.0017769574
## 6	919.5885	No	0	0.0037041528	0.044237010	0.0037041528


```
ggplot(datos, aes(x = balance, y = default_num)) +
  geom_point(aes(color = default), alpha = 0.30, size = 1.6) +
  geom_line(aes(y = pred_lineal), color = "#1B9E77", linewidth = 1.2) +
  geom_line(aes(y = pred_logistica), color = "#7570B3", linewidth = 1.2) +
  scale_color_manual(values = c("No" = "#2C7FB8", "Yes" = "#D95F02")) +
  labs(title = "Comparación final de modelos",
       subtitle = "Verde: regresión lineal | Morado: regresión logística",
```



```
x = "Balance",
y = "Estimación",
color = "Default") +
theme_minimal()
```

Comparación final de modelos

Verde: regresión lineal | Morado: regresión logística



11. Clasificación sencilla con regresión logística

La regresión logística estima probabilidades. Para convertir esas probabilidades en clases, usamos un punto de corte. El punto de corte más común es 0.5.

```
datos$pred_clase <- ifelse(datos$prob_default >= 0.45, "Yes", "No")

tabla_confusion <- table(Real = datos$default, Predicho = datos$pred_clase)
tabla_confusion
```

```
##      Predicho
## Real    No  Yes
##  No  9609  58
##  Yes   221 112
```

Calculamos una medida sencilla de desempeño: la exactitud o accuracy.

```
accuracy <- mean(datos$default == datos$pred_clase)
accuracy
```

```
## [1] 0.9721
```

Interpretación:

El valor de **accuracy** indica la proporción de clientes correctamente clasificados. Sin embargo, cuando una clase es mucho más frecuente que la otra, conviene revisar también la matriz de confusión.

12. Conclusión de la práctica

La regresión lineal simple y la regresión logística simple pueden parecer similares porque ambas usan una variable explicativa. Sin embargo, responden a problemas distintos.

Modelo	Variable respuesta	Forma del ajuste	Interpretación
Regresión lineal simple	Númerica continua	Recta	Estima un valor promedio
Regresión logística simple	Binaria	Curva en forma de S	Estima una probabilidad

Cuando la respuesta solo puede tomar los valores 0 y 1, la regresión logística suele ser más adecuada, porque sus predicciones se interpretan como probabilidades y siempre quedan entre 0 y 1.

13. Actividad para estudiantes

Responde brevemente:

1. ¿Por qué la regresión lineal no es la mejor opción cuando la variable respuesta es binaria? #porque puede generar probabilidades menores que 0 o mayores que 1
2. ¿Qué representa la curva logística? #representa la probabilidad estimada de que ocurra el evento
3. ¿Qué significa una probabilidad estimada cercana a 1? #significa que es muy probable que ocurra el evento
4. ¿Qué significa una probabilidad estimada cercana a 0? #significa que es muy poco probable que ocurra el evento
5. En la base **Default**, ¿qué ocurre con la probabilidad de default cuando aumenta **balance**? #cuando aumenta balance, aumenta la probabilidad de default